

MLP para clasificar anomalías territoriales de consenso en datos abiertos del Ecuador

MCDA · UIDE · Grupo 10 · Semana 1 · Perceptrón Multicapa
Integrantes: Wilson Paredes, Diana Tandalla, Alexander Luna y Bryan Sarmiento
Notebook: UIDE_G10_W1_MCDA_A-NOV25_Notebook.ipynb

1. Contextualización del problema

La tesis (Tema 50) consolida datos abiertos gubernamentales ecuatorianos por cantón mediante un data lake y detecta anomalías con tres métodos no supervisados: Isolation Forest, LOF y One-Class SVM. Para esta actividad se plantea una tarea de **clasificación binaria**: dada una combinación cantón-año descrita por indicadores institucionales, predecir si es una **anomalía de consenso** (marcada por al menos 2 de los 3 detectores). Se elige clasificación porque el objetivo es discreto (anómalo / normal) y se necesita una regla que se aplique a observaciones nuevas. La etiqueta proviene de los mismos detectores, por lo que el MLP es un *modelo sustituto del ensamble*: evalúa si la frontera de consenso es aprendible; no es una validación contra verdad de terreno, que aún no existe.

2. Estructuración y ficha técnica de los datos

Entrada: matriz cantón-año del data lake (221 cantones × 8 años = 1.768 filas; 28 indicadores de conteo de registros por conjunto de datos). Con el filtro de cobertura de la tesis (indicadores ≥40 %, filas ≥30 %) quedan **1.284 muestras × 4 variables** (79,4 % de densidad). Transformaciones: *log1p* del conteo; los ceros se tratan como dato faltante y se imputan con KNN (k=5), con lo que se obtiene la matriz de valores *M_V*; no hay variables categóricas, por lo que no se requiere one-hot. **Target**: 1 si ≥2 detectores (Isolation Forest, LOF, OC-SVM; contaminación 5 %) marcan la fila, 0 si no.

Característica	Valor
Muestras / variables	1.284 / 4 (x1 permisos de funcionamiento ARCSA, x2 encuesta Seguro Social Campesino IESS, x3 patrimonio inmaterial INPC, x4 registro de artistas RUAC)
Tipo	Númericas continuas, <i>log1p</i> (conteo), sin faltantes tras imputación (rango 0,7–10,2)
Balance	Normal 1.238 (96,4 %) · Anomalía 46 (3,6 %) — desbalance fuerte
Cobertura	221 cantones, 8 años (2019–2026), votos de los detectores: 1 voto = 75 filas, 2 votos = 20, 3 votos = 26




Figura 1. Balance de clases, anomalías en el plano x1–x3 y distribución de variables.

3. Pre procesamiento y división

Partición **80/20 estratificada** (1.027 / 257): con solo 46 anomalías, 80/20 deja ≈37 positivos para aprender y ≈9 para evaluar; 70/30 empobrece la clase rara en entrenamiento y 90/10 deja ≈5 positivos de prueba. Del train se aparta un 15 % de validación (estratificado) para vigilar la pérdida y el early stopping. El **StandardScaler se ajusta solo con el train** y se aplica a validación y prueba, evitando *data leakage*. Como *MLPClassifier* no admite pesos de clase, la clase minoritaria se **sobremuestrea únicamente en train**; validación y prueba conservan la proporción real. Aclaración: el KNN y el ensamble que generan la etiqueta se ajustaron sobre la matriz completa (procedimiento transductivo, no supervisado); el escalado y el entrenamiento supervisado sí respetan la separación.

4. Arquitectura del MLP

Elemento	Configuración y justificación
Capas	4 → 16 → 8 → 1 (≈190 parámetros). Red estrecha para ~1.000 muestras: limita el sobreajuste y aun así permite frontera no lineal
Activaciones	ReLU en ocultas (evita gradientes que se desvanecen); sigmoide en la salida (probabilidad de anomalía)
Pérdida	Entropía cruzada binaria + penalización L2 $\alpha \ W\ ^2/2$ ($\alpha=0$ salvo en la config. C)
Optimizador	Adam, lr=1e-3, batch=64, $\beta=(0,9; 0,999)$, 150 épocas con <i>partial_fit</i> para registrar curvas por época

5. Técnica complementaria: regularización L1/L2 y early stopping

Se compara el modelo sin regularizar contra cuatro variantes: **A** base sin sobremuestreo; **B** con sobremuestreo (referencia); **C** + L2 ($\alpha=0,1$); **D** + L1, implementada por umbral suave de los pesos tras cada época (*MLPClassifier* no trae L1 nativa); **E** + early stopping (paciencia 15 sobre la pérdida de validación, restaurando los mejores pesos). Para no depender de una partición con ≈ 9 anomalías de prueba, todo el flujo se repite con **10 semillas** y se reporta media $\pm$ desviación.





Figura 2. Pérdida (log-loss) de entrenamiento y validación por época, semilla 42.

6. Resultados y evaluación

Config.	Exactitud test	Precisión	Recall	F1	PR-AUC
A. Base	0.97 $\pm$ 0.00	0.83 $\pm$ 0.31	0.31 $\pm$ 0.14	0.45 $\pm$ 0.18	0.56 $\pm$ 0.12
B. +Sobremuestreo	0.97 $\pm$ 0.01	0.56 $\pm$ 0.12	0.68 $\pm$ 0.17	0.60 $\pm$ 0.11	0.70 $\pm$ 0.12
C. +L2 ($\alpha=0.1$)	0.96 $\pm$ 0.01	0.50 $\pm$ 0.12	0.72 $\pm$ 0.17	0.59 $\pm$ 0.12	0.73 $\pm$ 0.15
D. +L1	0.97 $\pm$ 0.01	0.58 $\pm$ 0.11	0.72 $\pm$ 0.17	0.63 $\pm$ 0.10	0.72 $\pm$ 0.11
E. +Early stopping	0.96 $\pm$ 0.01	0.42 $\pm$ 0.17	0.63 $\pm$ 0.28	0.49 $\pm$ 0.19	0.66 $\pm$ 0.20

Tabla 1. Métricas en prueba para la clase anomalía, media $\pm$ sd en 10 particiones. Con semilla 42 el modelo D logra exactitud 0,98, precisión 0,83 y recall 0,56 (5 de 9 anomalías; 1 falso positivo).



Figuras 3 y 4. Métricas medias $\pm$ sd por configuración y matrices de confusión (semilla 42).

Análisis de sobreajuste y subajuste. No hay subajuste: la pérdida de entrenamiento converge y la exactitud supera 96 %, así que la capacidad es suficiente. Sí hay **sobreajuste** en B–D: F1 de train $\approx 0,99$ (sobre el train balanceado) contra $\approx 0,6$ en prueba, y la pérdida de validación se aplanan en $\approx 0,05$ mientras la de train sigue bajando hasta $\approx 0,015$ (Fig. 2). El cuello de botella son los ≈ 37 positivos de entrenamiento, no la arquitectura. La **exactitud engaña** (>96 % aun prediciendo siempre «normal»), por lo que se priorizan F1, recall y PR-AUC. El modelo A es conservador (precisión alta, recall $\approx 0,31$); el sobremuestreo cambia ese equilibrio hacia más recall. L1 y L2 dan recall y PR-AUC ligeramente superiores y L1 el mayor F1 medio ($\approx 0,63$), pero todas las diferencias son menores a una desviación estándar (0,10–0,19), por lo que **no son concluyentes**. El early stopping no ayudó (F1 $\approx 0,49$): con ≈ 6 positivos en validación, la pérdida de validación es ruidosa y detiene el entrenamiento antes de tiempo.

7. Conclusiones y pasos siguientes

El MLP captura buena parte de la frontera de consenso del ensamble (PR-AUC $\approx 0,70-0,73$; exactitud $>96\%$), lo que indica que el consenso IF+LOF+OC-SVM es una regla aprendible y no ruido; no demuestra que las anomalías sean reales. La regularización aporta una mejora modesta y no firme. Para robustecer el trabajo en la tesis: (1) ampliar la matriz con más instituciones, pues solo 4 de 28 indicadores superan el 40 % de cobertura; (2) normalizar por población (tasa por mil habitantes); (3) validación cruzada estratificada repetida y umbral elegido por PR-AUC; (4) comparar contra regresión logística y bosques aleatorios; (5) contrastar las anomalías con casos validados por un experto institucional.

8. Enlace Google Colab desde GitHub

https://github.com/Alexander-Luna/NeuralNetworks-DeepLearning/blob/main/SEMANA%201/UIDE_G10_W1_MCDA_A-NOV25_Notebook.ipynb

9. Bibliografía

[1] Scikit-learn developers. Neural network models (supervised). https://scikit-learn.org/stable/modules/neural_networks_supervised.html · [2] Scikit-learn developers. Varying regularization in Multi-layer Perceptron. https://scikit-learn.org/stable/auto_examples/neural_networks/plot_mlp_alpha.html · [3] Datos Abiertos Ecuador. <https://datosabiertos.gob.ec>